Jakość wina: analiza danych i pytania badawcze

Uczenie maszynowe – Projekt 1, etap 1 (zima 2026)

Termin: 30.10.2026, 23:59 (Platon, zakładka „projekt”)

1. Informacja o zespole

Nazwisko i imię	Numer ID	Zakres pracy
Lavrenko Nazarii	71499	Pozyskanie i czyszczenie danych liczbowych (UCI Wine Quality), plik data/sources.json
Dorokhin Yevhenii	71545	EDA zbioru recenzji (dane tekstowe), analiza słownictwa
Kelyp Yaroslav	71503	Testy statystyczne, przedziały ufności i wielkości efektu (sekcja 5 notebooka)
Pitsukha Herman	71682	Repozytorium GitHub, README, przeglądarka wyników w Gradio (app.py)
Tsymbaliuk Roman	71676	Pytania badawcze, plan kolejnych etapów, redakcja raportu PDF

Repozytorium GitHub (kod, dane, raporty, README): https://github.com/H4V0C-Stack/Inzynieria-Sztucznej-Inteligencji

2. Informacja o danych

Projekt wykorzystuje dwa publicznie dostępne, rzeczywiste (nie symulowane ani syntetyczne) zbiory danych o winach: liczbowy zbiór pomiarów fizykochemicznych oraz tekstowy zbiór opisów degustacyjnych. Zbiory dotyczą różnych win i mają różne skale ocen, dlatego nie łączymy rekordów; łączy je wspólne pytanie badawcze o to, jakie informacje o ocenianej jakości wina niosą pomiary, a jakie opisy tekstowe (sekcja 4).

2.1 Zbiór 1 – dane liczbowe: UCI Wine Quality

- **Źródło:** UCI Machine Learning Repository, archive.ics.uci.edu/dataset/186/wine+quality; Cortez, Cerdeira, Almeida, Matos, Reis (2009), DOI: 10.24432/C56S3T; licencja CC BY 4.0.
- **Pliki:** winequality-red.csv (1 599 wierszy), winequality-white.csv (4 898 wierszy), winequality.names (opis); separator „;”, 12 kolumn: 11 cech fizykochemicznych i *quality*. Pobrano 23.10.2026.
- **Charakter danych:** pomiary laboratoryjne i ocena sensoryczna (skala 0–10) win „vinho verde” z północnej Portugalii. Ocena *quality* jest porządkowa. Nie ma braków danych.
- **Cechy:** kwasowość stała, kwasowość lotna, kwas cytrynowy, cukier resztkowy, chlorki, wolny i całkowity SO_2, gęstość, pH, siarczany, alkohol.

2.2 Zbiór 2 – dane w języku naturalnym: Wine Reviews

- **Źródło:** Kaggle, kaggle.com/datasets/zynicide/wine-reviews (Zack Thoutt); opisy degustacyjne ze strony Wine Enthusiast; plik winemag-data-130k-v2.csv; licencja CC BY-NC-SA 4.0. Pobrano 23.10.2026.
- **Rozmiar:** 129 971 recenzji, 13 kolumn danych (plus kolumna indeksu): kraj, opis (*description*), oznaczenie, ocena *points* (80–100), cena, prowincja, regiony, autor recenzji, tytuł, odmiana, winnica.
- **Dane tekstowe:** kolumna *description* (angielskie opisy degustacyjne, mediana 40 słów). Cena i metadane są danymi uzupełniającymi.

2.3 Podzbiory i sposób ich otrzymania

Nie używamy próbkowania ani podzbiorów losowych: analizujemy pełne pliki. Jedyne przekształcenia to czyszczenie opisane poniżej; wykonuje je kod w *analiza_wina.ipynb* (sekcje 1 i 2) i *app.py*. Surowe pliki są też w repozytorium w *data/raw*, a adresy źródłowe, daty pobrania i sumy kontrolne w *data/sources.json*. Plik z Kaggle wymaga zalogowania przy pobieraniu ze strony; kopia w repozytorium pozwala odtworzyć wyniki bez pobierania.

Zbiór	Wiersze surowe	Po czyszczeniu	Reguła
Wina czerwone	1 599	1 359	usunięto 240 powtórzonych wierszy
Wina białe	4 898	3 961	usunięto 937 powtórzonych wierszy
Recenzje	129 971	119 954	bez kolumny indeksu, bez powtórzonych wierszy (-9 983) i powtórzonych opisów (-34, po normalizacji wielkości liter i spacji); pierwsze wystąpienie zostaje

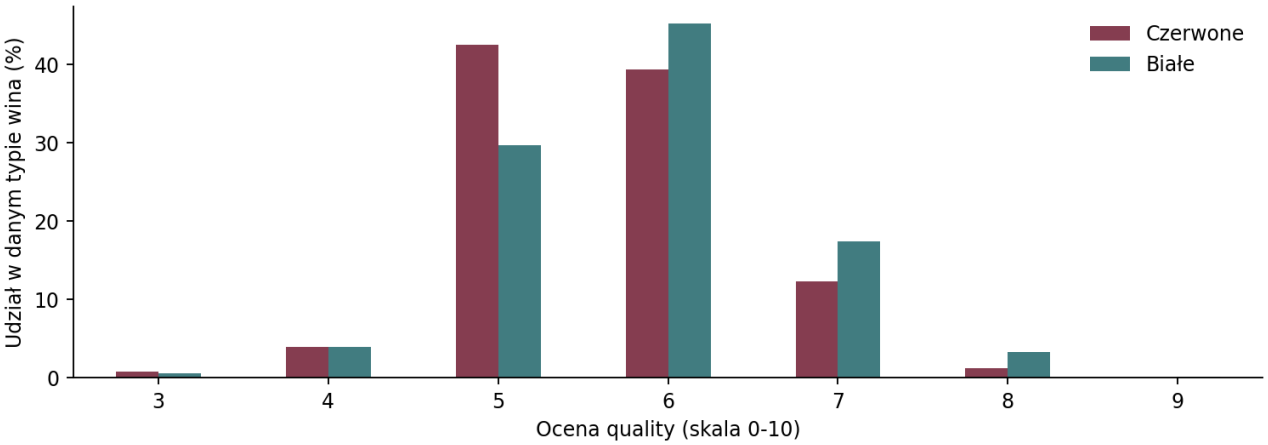
Brakujących cen (ok. 7% recenzji) nie uzupełniamy, a obserwacji odstających nie usuwamy.

3. Analiza eksploracyjna danych (EDA)

3.1 Dane liczbowe (UCI Wine Quality)

Miara	Czerwone	Białe
Wiersze surowe	1 599	4 898
Po usunięciu powtórzeń	1 359	3 961
Brakujące wartości	0	0
Średnia quality	5.62	5.85
Mediana quality	6	6
Oceny 5 lub 6 (%)	81.82	74.80
Oceny ≥ 7 (%)	13.54	20.83

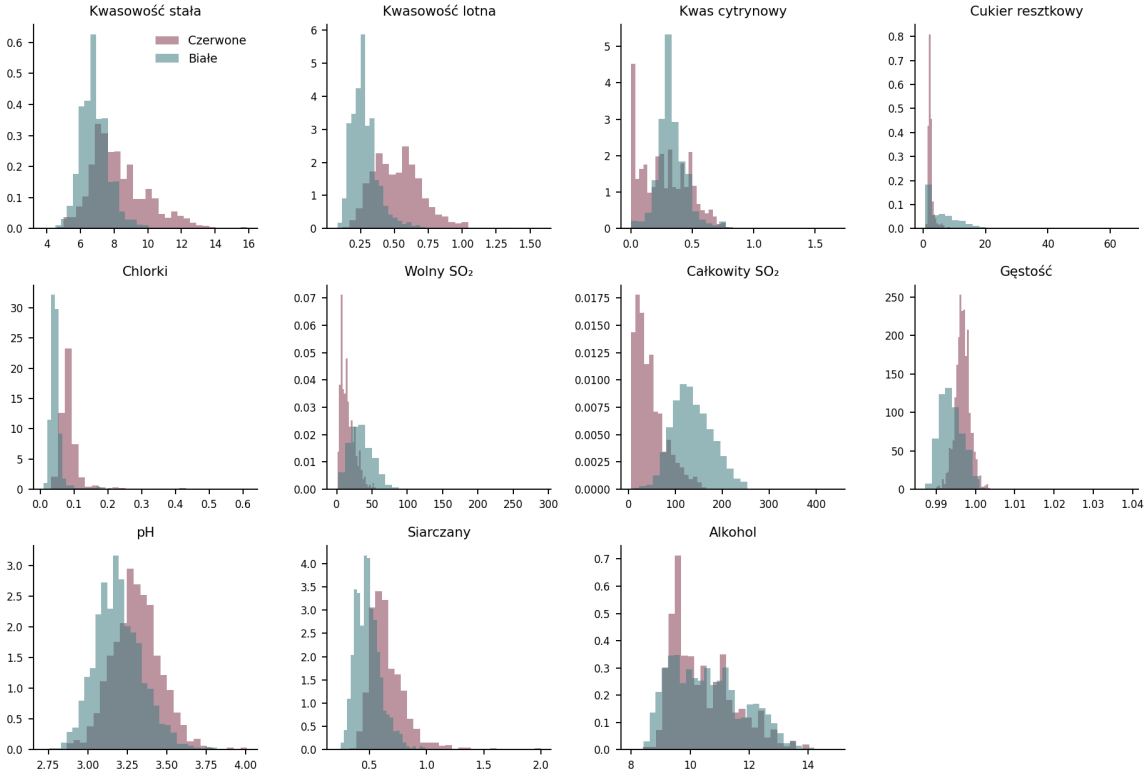
Oceny 5 i 6 dominują (82% win czerwonych i 75% białych), a oceny skrajne są rzadkie, dlatego rozkład jest silnie skoncentrowany. Białe wina mają nieco wyższą średnią ocenę (5,85 wobec 5,62).



Rysunek 1. Rozkład ocen quality w winach czerwonych i białych (udział w danym typie).

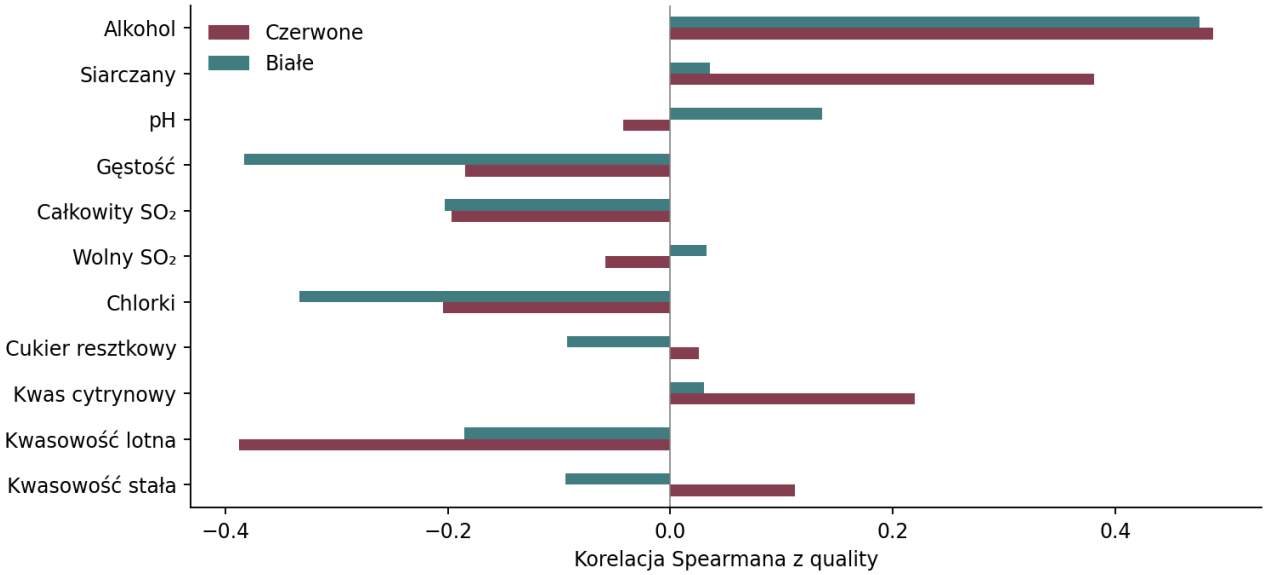
Obserwacje odstające wg reguły IQR (1,5·IQR) to liczba wartości poza wąsami; nie usuwamy ich, bo mogą opisywać prawdziwe, nietypowe wina.

Cecha	Czerwone	Białe
kwasowość stała	41	106
kwasowość lotna	19	133
kwas cytrynowy	1	223
cukier resztkowy	126	16
chlorki	87	178
wolny SO_2	26	44
całkowity SO_2	45	14
gęstość	35	6
pH	28	46
siarczany	55	96
alkohol	12	0

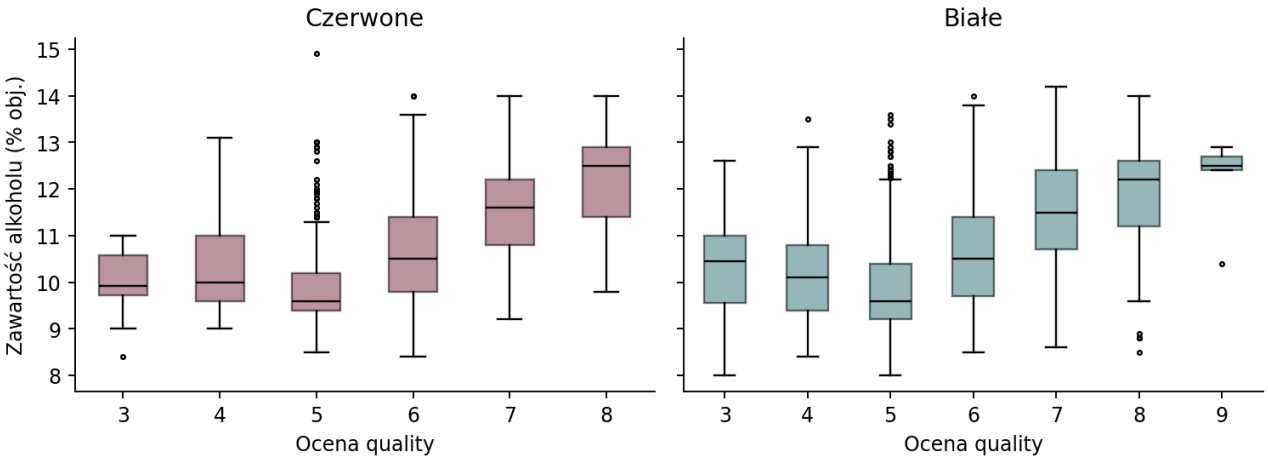


Rysunek 2. Rozkłady cech fizykochemicznych: czerwone i białe wina. Cechy są w większości prawoskośne; białe i czerwone różnią się położeniem i rozrzutem.

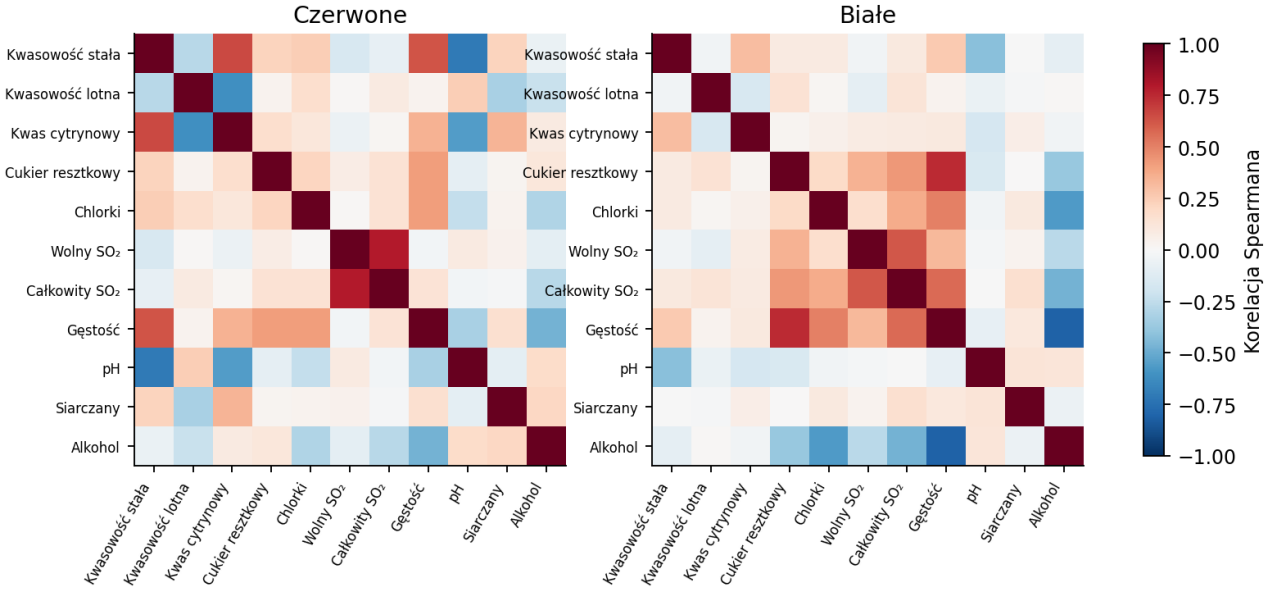
Test D'Agostino–Pearsona odrzuca normalność rozkładu praktycznie dla wszystkich cech ($p < 0{,}001$, najczęściej znacznie mniej), a największą skośność mają chlorki (≈5) i cukier resztkowy w winach czerwonych (≈4,5). Dlatego stosujemy testy rangowe. Pełna tabela: *output/tables/normality_tests.csv*.



Rysunek 3. Korelacje Spearmana cech fizykochemicznych z oceną quality (osobno dla typów wina).



Rysunek 4. Zawartość alkoholu w grupach ocen quality.



Rysunek 5. Korelacje Spearmana między cechami (wielokolinearność).

Najsilniejsze zależności między cechami (|ρ| ≥ 0,6):

Typ	Cecha 1	Cecha 2	ρ
Białe	Gęstość	Alkohol	-0.808
Czerwone	Wolny SO_2	Całkowity SO_2	0.790
Białe	Cukier resztkowy	Gęstość	0.743
Czerwone	Kwasowość stała	pH	-0.709
Czerwone	Kwasowość stała	Kwas cytrynowy	0.657
Czerwone	Kwasowość stała	Gęstość	0.627
Białe	Wolny SO_2	Całkowity SO_2	0.620
Czerwone	Kwasowość lotna	Kwas cytrynowy	-0.611

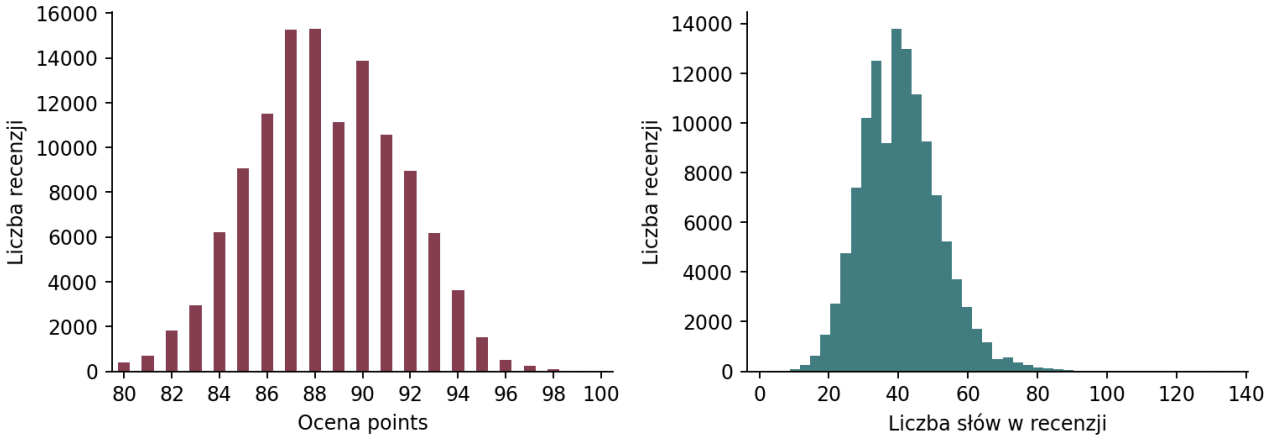
3.2 Dane tekstowe (Wine Reviews)

Po czyszczeniu pozostaje 119 954 recenzji, z czego 111 566 ma cenę. Ocena *points* ma średnią 88,4 i medianę 88, a opis ma medianę 40 słów. W surowym pliku (129 971 recenzji) najczęściej brakuje drugiego regionu (61%), oznaczenia (29%), danych autora recenzji (24% w polu Twittera, 20% w nazwisku) i pierwszego regionu (16%); brak ceny dotyczy 6,9% recenzji. Tabela poniżej pokazuje braki w surowym pliku.

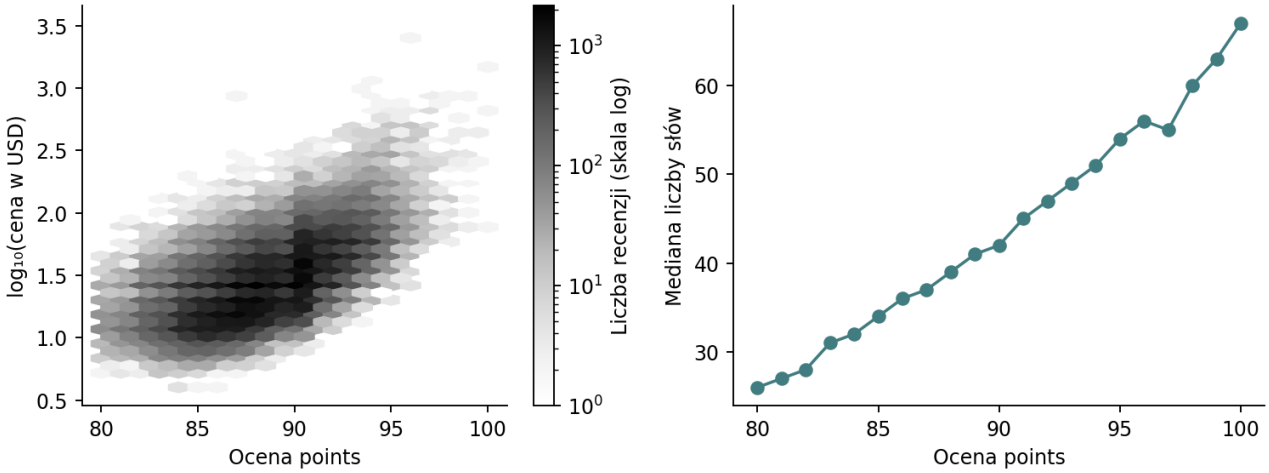
Kolumna	Braki (n)	Braki (%)
region_2	79 460	61.1

Kolumna	Braki (n)	Braki (%)
designation	37 465	28.8
taster_twitter_handle	31 213	24.0
taster_name	26 244	20.2
region_1	21 247	16.3
price	8 996	6.9
province	63	0.0
country	63	0.0

Miara	points	price	word_count	char_count
count	119 954	111 566	119 954	119 954
mean	88.4	35.6	40.7	242.8
std	3.1	42.1	11.1	67.1
min	80	4	3	20
25%	86	17	33	197
50%	88	25	40	237
75%	91	42	47	283
max	100	3 300	134	829

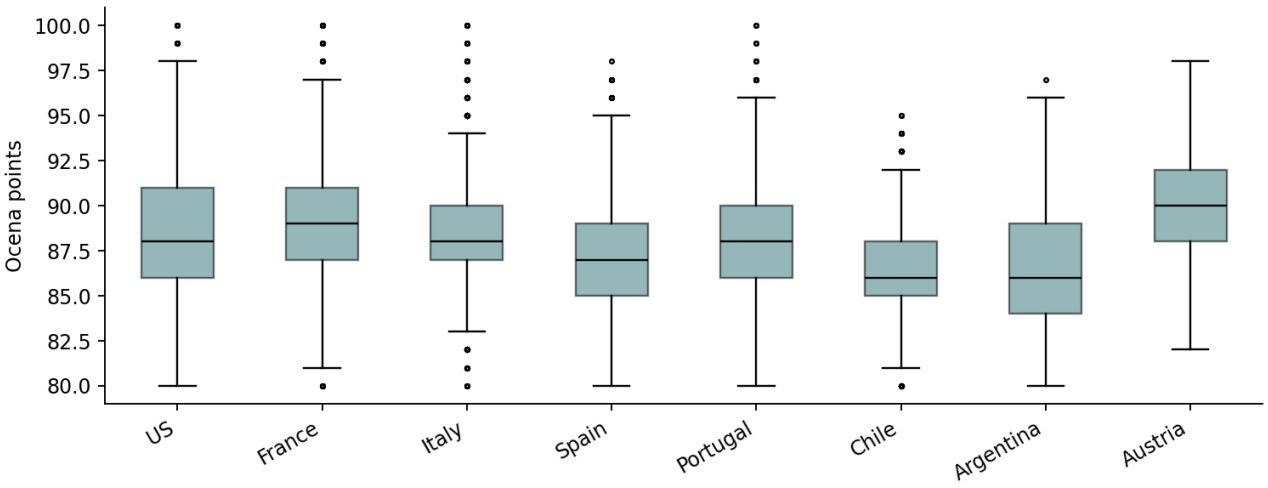


Rysunek 6. Rozkład ocen points oraz liczby słów w recenzji.

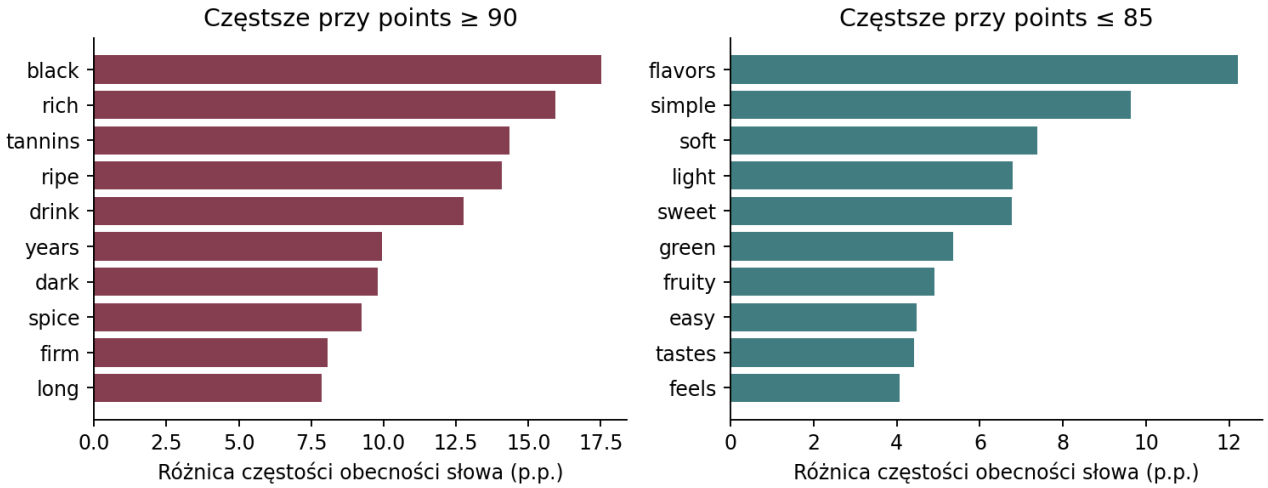


Rysunek 7. Cena (skala logarytmiczna) a ocena oraz mediana liczby słów opisu w zależności od oceny.

Najliczniejsze kraje to USA (50 447 recenzji), Francja (20 351), Włochy (17 921), Hiszpania (6 116) i Portugalia (5 256); najczęstsze odmiany to Pinot Noir (12 277), Chardonnay (10 867) i Cabernet Sauvignon (8 837).



Rysunek 8. Rozkład ocen points w ośmiu najliczniejszych krajach.



Rysunek 9. Słowa, których odsetek recenzji różni się najbardziej między grupami points ≥ 90 i points ≤ 85 (różnica w punktach procentowych). Opis bez kontroli długości, odmiany i autora.

3.3 Testy statystyczne

Ponieważ rozkłady nie są normalne, a *quality* i *points* są oceniami porządkowymi, stosujemy testy rangowe. Do każdego wyniku podajemy wielkość efektu, a przy wielu porównaniach korektę Bonferroniego, bo przy tak dużych próbach bardzo niskie p nie oznacza dużego efektu.

Mann–Whitney: wina czerwone vs białe (efekt r = rank-biserial, od −1 do 1). Największe różnice dotyczą całkowitego SO_2, chlorków i kwasowości lotnej; różnica w ocenie quality jest mała (|r| ≈ 0,15).

Cecha	Mediana czerwone	Mediana białe	Efekt r	p (Bonferroni)
Kwasowość stała	7.900	6.800	0.568	4.8e-214
Kwasowość lotna	0.520	0.260	0.796	<1e-300
Kwas cytrynowy	0.260	0.320	-0.209	1.5e-29
Cukier resztkowy	2.200	4.700	-0.291	1.0e-56
Chlorki	0.079	0.042	0.884	<1e-300
Wolny SO_2	14	33	-0.684	<1e-300
Całkowity SO_2	38	133	-0.899	<1e-300
Gęstość	0.997	0.994	0.600	7.3e-239
pH	3.310	3.180	0.422	1.3e-118
Siarczany	0.620	0.480	0.661	2.8e-289
Alkohol	10.200	10.400	-0.066	3.1e-03
quality	6	6	-0.149	2.4e-17

Korelacje Spearmana z quality z 95% przedziałem ufności (przybliżenie Fieller'a); „n.i." oznacza brak istotności po korekcie Bonferroniego (22 porównania). Najsilniejsza jest dodatnia zależność z alkoholem (ρ ≈ 0,48 w obu typach).

Cecha	Czerwone	Białe
Kwasowość stała	0.11 [0.06; 0.17]	-0.09 [-0.13; -0.06]
Kwasowość lotna	-0.39 [-0.43; -0.34]	-0.19 [-0.22; -0.15]
Kwas cytrynowy	0.22 [0.17; 0.27]	0.03 [-0.00; 0.06] (n.i.)
Cukier resztkowy	0.03 [-0.03; 0.08] (n.i.)	-0.09 [-0.12; -0.06]
Chlorki	-0.20 [-0.26; -0.15]	-0.33 [-0.36; -0.30]
Wolny SO_2	-0.06 [-0.11; -0.00] (n.i.)	0.03 [0.00; 0.06] (n.i.)
Całkowity SO_2	-0.20 [-0.25; -0.14]	-0.20 [-0.23; -0.17]
Gęstość	-0.18 [-0.24; -0.13]	-0.38 [-0.41; -0.36]
pH	-0.04 [-0.10; 0.01] (n.i.)	0.14 [0.10; 0.17]
Siarczany	0.38 [0.33; 0.43]	0.04 [0.00; 0.07] (n.i.)
Alkohol	0.49 [0.45; 0.53]	0.48 [0.45; 0.50]

Kruskal–Wallis: zawartość alkoholu w grupach jakości (grupy z n ≥ 5). Różnice są duże (ε^2 ≈ 0,24–0,27), co zgadza się z korelacjami; to związek opisowy, nie przyczynowy.

Typ	Liczba grup	H	p	ε^2
Czerwone	6	368.56	0.00	0.27
Białe	7	966.10	0.00	0.24

Kruskal–Wallis: oceny points w grupach. Efekt jest największy dla autora recenzji (ε^2 ≈ 0,07), a dla odmiany i kraju mały; modele tekstowe warto więc oceniać z podziałem uwzględniającym autora.

Grupowanie	H	p	ε^2
kraj (5 największych)	1 212	4.0e-261	0.012
odmiana (5 największych)	959.196	2.5e-206	0.021
autor recenzji (5 najliczniejszych)	4 734	<1e-300	0.073

Recenzje: ρ Spearmana – cena i długość opisu a ocena. Długość opisu rośnie z oceną; w porównaniu grup points ≥ 90 i ≤ 85 opisy wyżej ocenianych są dłuższe (Mann–Whitney, efekt r ≈ 0,68).

Zależność	n	ρ	CI95 dół	CI95 góra	p
cena - points	111 566	0.613	0.609	0.616	<1e-300
liczba słów - points	119 954	0.505	0.501	0.509	<1e-300

Słownictwo: test χ^2 dla obecności słowa w grupach points ≥ 90 i ≤ 85 (pięć słów w każdą stronę, korekta Bonferroniego na wszystkie słowa). Różnice są istotne, ale opisują wzorce w tekstach, a nie przyczynę oceny.

Słowo	Różnica (p.p.)	χ^2	p (Bonferroni)
black	17.5	2 762	<1e-300
rich	15.9	2 926	<1e-300
tannins	14.4	1 664	<1e-300
ripe	14.1	1 800	<1e-300
drink	12.8	1 279	9.4e-277
sweet	-6.8	702.6	1.5e-151
light	-6.8	884.3	4.6e-191
soft	-7.4	913.3	2.3e-197
simple	-9.6	4 257	<1e-300
flavors	-12.2	866.7	3.1e-187

4. Pytania badawcze

Pytanie główne: Jakie informacje o ocenianej jakości wina zawierają pomiary fizykochemiczne i opisy degustacyjne oraz jakie wzorce można rozpoznać w każdym z tych źródeł?

Pytanie 1. Które cechy fizykochemiczne najsilniej wiążą się z oceną jakości i czy zależności różnią się między winami czerwonymi a białymi?

Hipoteza: Dodatnia zależność alkoholu występuje w obu typach, a znaczenie pozostałych cech jest różne (potwierdzone wstępnie: alkohol $\rho \approx 0{,}48$; kwasowość lotna i siarczany ważne dla czerwonych, chlorki i gęstość dla białych).

Metody: Etap 2: regresja liniowa/Ridge i random forest, baza medianowa; MAE, RMSE.

Pytanie 2. Czy treść opisu degustacyjnego pozwala przewidywać ocenę lepiej niż sama długość recenzji?

Hipoteza: Treść wnosi dodatkową informację poza długością (długość ma $\rho \approx 0{,}5$ z oceną).

Metody: Etap 2–3: baza medianowa, model długości, TF-IDF + Ridge, embeddingi transformera + regresja; ten sam podział i metryki. Wejściem jest wyłącznie *description*.

Pytanie 3. Czy dodatnia zależność ceny od oceny występuje także w obrębie porównywalnych grup win?

Hipoteza: Kierunek jest dodatni również wewnątrz popularnych odmian (wstępnie $\rho \approx 0{,}55$–$0{,}69$ w pięciu największych).

Metody: Spearman i mediany w grupach $n \geq 100$, następnie kontrola kraju i autora oraz raportowanie braków cen.

Pytanie 4. Czy bez użycia ocen można odkryć grupy win lub opisów, które różnią się później rozkładem ocen?

Hipoteza: Istnieją interpretowalne grupy o różnych profilach i ocenach.

Metody: K-means i klasteryzacja hierarchiczna osobno dla cech chemicznych i reprezentacji tekstu; silhouette, stabilność, interpretowalność; oceny porównujemy dopiero po ustaleniu grup.

Powiązanie z wymaganiami kolejnych etapów projektu:

Wymaganie projektu	Planowane użycie	Pytania
Metody nadzorowane (2)	Ridge i random forest (dane liczbowe); TF-IDF + Ridge (tekst)	P1, P2
Metody nienadzorowane (2)	K-means i klasteryzacja hierarchiczna	P4
Modele NLP	TF-IDF i model długości jako punkt odniesienia	P2
Modele transformerowe	Embeddingi zdań/opisów + regresja	P2, P4
Interfejs	Gradio (app.py): EDA i wyniki	wszystkie

Hipotezy powstały po obejrzeniu całej próby i są eksploracyjne. Zbiory nie są reprezentatywne dla rynku wina, korelacje opisują próbę, a nie związki przyczynowe. Przed modelowaniem ustalimy podział danych (z grupowaniem rekordów tego samego wina), a preprocessing dopasujemy tylko na zbiorze treningowym.

5. Repozytorium i odtworzenie wyników

Link do repozytorium: https://github.com/H4V0C-Stack/Inzynieria-Sztucznej-Inteligencji

- **Kod:** *analiza_wina.ipynb* (EDA, testy, pytania), *app.py* (interfejs Gradio), *report/build_report.py*.
- **Dane:** *data/raw* (4 pliki), *data/sources.json* (źródła, sumy kontrolne).
- **Wyniki:** *output/figures* (wykresy PNG), *output/tables* (tabele CSV), niniejszy raport PDF.
- **Odtworzenie:** *pip install -r requirements.txt*, uruchomienie notebooka od góry do dołu, *python app.py* – przeglądarka wyników w Gradio (zakładki: dane liczbowe, recenzje, tabele, wykresy).